

Predictor de Tiempo de Hospitalización

Carreño Córdón Daniela, Centeno Rivera Daniel, Maccoy Artola Brayton y
Venegas Bermúdez Kathleen

Universidad Fidélitas, Costa Rica

dcarreno90347@ufide.ac.cr

dcenteno60883@ufide.ac.cr

bmaccoy0474@ufide.ac.cr

kvenegas30876@ufide.ac.cr

Abstract— This project proposes the development of a machine learning model to predict patient hospitalization time based on clinical and demographic data. Using a synthetic healthcare dataset, the model analyzes key variables to estimate hospital stay duration and optimize resource planning. The system aims to improve decision-making by providing accurate, data-driven predictions that enhance hospital efficiency and patient care.

I. INTRODUCCIÓN

El análisis del tiempo de estancia hospitalaria (Length of Stay) es fundamental para optimizar la planificación de recursos, la gestión de camas y la eficiencia operativa dentro de los centros de salud. A partir del Healthcare Dataset, este proyecto desarrolla un modelo predictivo que estima la duración de la estancia de los pacientes utilizando técnicas de machine learning. Para ello se implementa un proceso completo que incluye exploración de datos, preprocesamiento mediante pipelines, ingeniería de características y la evaluación de modelos con métricas de desempeño. El objetivo es construir una solución confiable, reproducible y útil para apoyar la toma de decisiones en el contexto hospitalario.

Dado que la duración de la estancia influye directamente en la disponibilidad de camas, la asignación de personal médico y la eficiencia global del sistema, contar con una herramienta capaz de predecir este valor aporta un beneficio significativo a la gestión hospitalaria. A lo largo del proyecto se analizan los atributos del conjunto de datos, se construyen diferentes modelos y se selecciona aquel con mejor rendimiento sobre un conjunto estratificado de prueba. Finalmente, se examina la importancia de las características más influyentes en la predicción, con el fin de generar un marco interpretativo que pueda servir como base para futuras mejoras o aplicaciones en entornos reales.

I. ANTECEDENTES

En el sector salud, la planificación de recursos es un desafío constante. Factores como la ocupación hospitalaria, la disponibilidad de camas, el personal médico y los suministros deben gestionarse cuidadosamente para garantizar una atención oportuna y de calidad. No obstante, la variabilidad en la duración de las estancias hospitalarias dificulta esta tarea, ya

que cada paciente presenta características y condiciones clínicas únicas.

Las estimaciones sobre el tiempo de la hospitalización se han basado en las experiencias del personal médico. Estos métodos pueden resultar imprecisos y poco adaptables a las particularidades de cada paciente. Por eso se han desarrollado distintas estrategias administrativas y tecnológicas que buscan mejorar la eficiencia en la gestión hospitalarias.

En muchos países la modernización de los sistemas de salud ha dado muy buenos resultados, ya que ha ayudado a usar mejores los recursos y ha mostrado lo valioso que es tener herramientas que van a permitir planificar y dar seguimiento a los procesos dentro de los hospitales.

II. DEFINICIÓN DEL PROBLEMA

El Hospital MediCare enfrenta dificultades para calcular de manera precisa los tiempos de hospitalización de sus pacientes. Actualmente no se consideran factores importantes como la enfermedad diagnosticada ni los resultados de las pruebas médicas, lo que provoca estimaciones poco confiables.

Además, el proceso se realiza de forma manual, lo que lo hace lento y limita la capacidad de brindar respuestas rápidas a los pacientes y al personal médico. Esto genera atrasos, insatisfacción y un uso poco eficiente de los recursos hospitalarios.

Por otro lado, las condiciones cambian constantemente (como ingresos de emergencia o la evolución de la enfermedad), pero el método actual no se ajusta con la misma rapidez. Esto reduce la posibilidad de tomar decisiones basadas en datos y de anticipar de forma adecuada los tiempos de espera.

III. JUSTIFICACIÓN

Se argumenta la necesidad de establecer un sistema

automatizado que facilite la integración de diversas variables médicas y actualice los tiempos de espera en tiempo real. Así, se incrementaría la exactitud de las valoraciones, se perfeccionaría el servicio y además se promovería una gestión hospitalaria más eficiente.

En la actualidad los avances tecnológicos permiten analizar grandes volúmenes de datos para poder encontrar patrones complejos que ayuden a estimar con mayor exactitud la duración esperada de una estancia hospitalaria. Esto demuestra el valor estratégico de la predicción precisa dentro de la gestión hospitalaria moderna.

IV. OBJETIVOS

A. General

Desarrollar un modelo de aprendizaje automático que prediga el tiempo de hospitalización de un paciente, basado en su condición médica para tomar decisiones como la capacidad del hospital.

B. Específicos

- Realizar un análisis exploratorio del conjunto de datos de pacientes hospitalizados para depurar datos, identificar patrones y relaciones entre las variables.
- Entrenar modelos predictivos utilizando algoritmos de regresión para estimar el tiempo de hospitalización.
- Evaluar el rendimiento de los modelos para medir la precisión de las predicciones y seleccionar el que tenga el mejor desempeño.
- Realizar la optimización de hiper parámetros del modelo seleccionado para mejorar su rendimiento.
- Desarrollar un sistema automatizado que permita utilizar las predicciones del modelo para ajustar los tiempos de hospitalización y tomar decisiones estratégicas del hospital.

V. CONJUNTO DE DATOS

A. Descripción

Healthcare Dataset es un conjunto de datos sintético (ficticio) creado con fines educativos y de experimentación para análisis de datos y aprendizaje automático. Se pretende emular registros hospitalarios con atributos demográficos, médicos, de facturación, admisiones, etc.

B. Características

El *dataset* consta de las siguientes columnas:

- **Name:** Esta columna representa el nombre del paciente asociado con el registro médico.
- **Age:** La edad del paciente al momento de la admisión, expresada en años.
- **Gender:** Indica el género del paciente, ya sea "Male" or "Female".

- **Blood Type:** El tipo de sangre del paciente, que puede ser uno de los tipos comunes (por ejemplo, "A+", "O-", etc.).
- **Medical Condition:** Esta columna especifica la condición médica principal o el diagnóstico asociado con el paciente, como "Diabetes," "Hypertension," "Asthma", entre otros.
- **Date of Admission:** La fecha en la que el paciente fue admitido en el centro de salud.
- **Doctor:** El nombre del médico responsable del cuidado del paciente durante su admisión.
- **Hospital:** Identifica el centro de salud u hospital donde el paciente fue admitido.
- **Insurance Provider:** Esta columna indica el proveedor de seguro médico del paciente, que puede ser una de varias opciones, incluyendo "Aetna", "Blue Cross", "Cigna", "UnitedHealthcare" o "Medicare".
- **Billing Amount:** El monto de dinero facturado por los servicios de atención médica del paciente durante su admisión. Se expresa como un número con decimales.
- **Room Number:** El número de la habitación donde el paciente fue alojado durante su admisión.
- **Admission Type:** Especifica el tipo de admisión, que puede ser "Emergency," "Elective," or "Urgent", reflejando las circunstancias de la admisión.
- **Discharge Date:** La fecha en la que el paciente fue dado de alta del centro de salud, basada en la fecha de admisión y un número aleatorio de días dentro de un rango realista.
- **Medication:** Identifica un medicamento recetado o administrado al paciente durante su admisión. Ejemplos incluyen "Aspirin," "Ibuprofen," "Penicillin," "Paracetamol," y "Lipitor".
- **Test Results:** Describe los resultados de una prueba médica realizada durante la admisión del paciente. Los valores posibles incluyen "Normal," "Abnormal," o "Inconclusive" indicando el resultado de la prueba.

Nota: La variable objetivo se obtendrá de la resta entre *Discharge Date* y *Date of Admission*.

C. Tamaño

- **Instancias:** 55,500 registros.
- **Atributos:** 15 características.

D. Limitaciones

- El conjunto de datos es sintético y fue creado con fines educativos, por lo que no representa registros médicos reales.
- Al no provenir de un entorno hospitalario real, los resultados del modelo podrían no generalizarse directamente a casos prácticos en instituciones de salud.

E. Acceso

- Disponible [Healthcare Data Set](#).

VI. ANÁLISIS EXPLORATORIO

1. Transformaciones

De acuerdo con las transformaciones realizadas en el dataset, se destaca la identificación de columnas que requerían ser ajustadas para posibilitar el trabajo con estas de manera correcta. Por ejemplo, la columna “*Discharge Date*” fue transformada para separar el año y el mes, lo que permitió analizar mejor los periodos en los que ocurren las hospitalizaciones.

También se agruparon los valores de edad en categorías, creando una nueva columna llamada “*age_cat*”, para observar cómo varía el tiempo de hospitalización según los grupos de edad.

Además, se transformaron las columnas de texto como *Doctor*, *Hospital* e *Insurance Provider*, asignándoles valores numéricos para poder incluirlas en los análisis y comparaciones posteriores.

Estas transformaciones, por consiguiente, ayudaron a preparar los datos y a facilitar las siguientes etapas del estudio.

2. Identificación de nulos

Inicialmente, durante el análisis exploratorio se comprobó que el conjunto de datos no presentaba valores nulos.

Por tanto, se decidió incorporar de forma intencional 800 valores nulos en tres variables específicas: *Billing Amount*, *Medication* y *Test Results*, con el objetivo de simular la presencia de datos incompletos y permitir la aplicación de técnicas de imputación.

Esta incorporación controlada facilita la evaluación de distintos métodos de tratamiento de nulos y garantiza que el proceso de limpieza pueda replicar condiciones reales en las que la información puede estar ausente o incompleta.

3. Correlaciones

Se calculó la correlación entre las variables numéricas y la duración de hospitalización. Los resultados mostraron relaciones lineales muy débiles, lo que indicó que factores como edad, monto facturado o número de habitación no explicaban

por sí solos los días de internamiento. Esto sugirió que las variables individuales no tenían un efecto directo fuerte sobre el resultado y que el comportamiento de la estancia hospitalaria dependía de interacciones más complejas.

También se evaluaron variables categóricas codificadas, como resultados de pruebas o tipo de admisión, pero su correlación directa con la variable objetivo también fue baja. Esto confirmó que el dataset no contenía patrones simples detectables mediante correlación y que era necesario aplicar técnicas que permitieran capturar relaciones no lineales.

A partir de este hallazgo, se justificó la creación de nuevas variables derivadas, como el ratio entre monto facturado y edad, y la aplicación de transformaciones logarítmicas. Además, se optó por entrenar modelos más robustos, como Random Forest, que detectan interacciones complejas incluso cuando las correlaciones tradicionales no revelan patrones claros.

4. Candidatos para estratificar conjuntos de entrenamiento y prueba

En esta etapa se definieron los posibles criterios para realizar la estratificación del dataset, con el objetivo de garantizar una distribución equilibrada de los datos entre los conjuntos de entrenamiento y prueba.

Se analizaron distintas variables candidatas, priorizando aquellas que mostraban una relación significativa con la variable objetivo *Length of Stay*, como la edad, el tipo de admisión y el monto de facturación. Estas variables reflejan patrones importantes del comportamiento hospitalario y permiten representar de forma más justa las diferentes condiciones de los pacientes.

De este modo, la selección del atributo para la estratificación no solo se basó en su distribución, sino también en su capacidad para mantener la coherencia y diversidad del conjunto de datos original en ambas particiones.

VII. CREACIÓN DE CONJUNTOS DE ENTRENAMIENTO Y PRUEBAS

1. Creación de conjuntos aleatorio

Para el desarrollo del modelo predictivo, el conjunto de datos se dividió en dos mediante un proceso aleatorio: 80% de los registros se asignaron al conjunto de entrenamiento y el 20% restante al conjunto de prueba. Esta proporción se definió para garantizar que el modelo tuviera suficiente información para aprender los patrones sin comprometer la calidad de la data.

El conjunto de entrenamiento contiene la mayoría de las observaciones (44 400 registros) y se utilizó en las etapas

de análisis, imputación y preprocesamiento. Por su parte, el conjunto de prueba (11 100 registros) se mantuvo sin alteraciones.

Al analizar ambos conjuntos, se observó que mantienen distribuciones similares en las siguientes variables: *Age*, *Gender*, *Billing Amount* y *Medical Condition*. Esto confirma que el proceso aleatorio conservó la representatividad de la muestra original.

2. Creación de conjuntos estratificados

Se estratificó tomando como variable base la edad de los pacientes, ya que refleja una distribución representativa de la población hospitalaria y puede influir directamente en la duración de la hospitalización.

Por lo que, se creó una variable categórica llamada *age_cat*, que agrupa las edades en cinco rangos. Esta clasificación permitió visualizar cómo se distribuyen los pacientes por grupo etario, evidenciando que los adultos representan la mayor proporción del conjunto de datos.

Al aplicar la estratificación, se obtuvieron proporciones similares de cada grupo en los conjuntos de entrenamiento y prueba, garantizando que ambos mantuvieran la misma diversidad poblacional. Esto asegura que el modelo no aprenda de forma sesgada hacia un grupo de edad específico.

3. Comparación y selección

Una vez creados los conjuntos aleatorio y estratificado, se compararon las proporciones de pacientes en cada grupo de edad para verificar cuál método representaba mejor al conjunto original.

Los resultados mostraron que el estratificado mantiene prácticamente las mismas proporciones de edad respecto al dataset completo, con diferencias mínimas, menores al 0.1%. En cambio, la división aleatoria presenta pequeñas variaciones, especialmente en los grupos de edad extrema (menores de 18 y mayores de 65 años).

Por esta razón, se eligió el conjunto estratificado para entrenar y probar el modelo, ya que conserva mejor la representatividad de los datos y permite obtener resultados más equilibrados y precisos.

VIII. PREPROCESAMIENTO

1. Transformaciones

Durante el preprocesamiento del conjunto de datos, se definieron las transformaciones aplicadas a cada variable según su naturaleza y utilidad dentro del modelo.

- La columna *Name* se excluyó del análisis, ya que funciona únicamente como un identificador textual sin aportar valor predictivo.
- La variable *Age* fue utilizada para realizar cálculos y

estandarizaciones, además de emplearse junto con *Billing Amount* para obtener una relación entre ambos valores.

- En el caso de *Gender*, se aplicaron procesos de imputación y codificación para transformar los datos de texto en valores numéricos manejables por el modelo.
- De forma similar, las columnas *Blood Type* y *Medical Condition* también se sometieron a imputación y codificación, debido a que contienen información categórica relevante para el análisis.
- Por su parte, *Date of Admission* no se consideró como variable predictora, ya que su propósito principal fue contribuir al cálculo de la duración de la hospitalización.
- Las columnas *Doctor* y *Hospital* se descartaron del modelo, al determinarse que no aportaban información significativa para la predicción.
- En cambio, *Insurance Provider* fue transformada mediante imputación y codificación, para permitir su integración en el análisis.
- La variable *Billing Amount* recibió un tratamiento más completo: se aplicaron procesos de imputación, estandarización y una transformación logarítmica, además de emplearse para calcular un ratio con la edad del paciente.
- El campo *Room Number* también fue estandarizado e imputado, al representar un valor numérico susceptible a faltantes.
- La columna *Admission Type* se codificó e imputó, pues contiene categorías relacionadas con el tipo de ingreso hospitalario.
- En tanto, *Discharge Date* no se usó como variable predictora, ya que su función fue únicamente calcular la duración de la estancia hospitalaria.

Finalmente, las variables *Medication* y *Test Results* fueron sometidas a imputación y codificación, mientras que *Length of Stay* se mantuvo sin transformaciones, al ser la variable objetivo que se busca predecir.

2. Eliminación o imputación de nulos

En el proyecto se revisaron los valores faltantes del conjunto de datos para que no se vea afectado los cálculos ni las visualizaciones.

- Se eliminaron filas y columnas que tenían valores vacíos.
- Cuando los valores faltantes eran muy pocos, se reemplazaron según el tipo de variable.

3. Creación de atributos

En la etapa de análisis y preparación de datos, se crearon atributos adicionales que enriquecen el dataset y permiten mejorar la capacidad predictiva del modelo. Por ejemplo, a partir de las fechas de ingreso y alta

hospitalaria, se calculó la variable *"Length of Stay"* (duración de la estancia), fundamental para el objetivo de predicción [1]. También se generaron otras variables derivadas, como la categorización de la edad de los pacientes en rangos (*"age_cat"*) [2], y las variables de los indicadores que resumen el comportamiento y agrupan características relevantes.

4. Escalado

El escalado es un proceso que transforma los valores numéricos de las variables para que estén en un rango compatible y comparable, normalmente entre 0 y 1, o con media 0 y desviación estándar 1 [3]. Esto es importante porque muchos algoritmos de aprendizaje automático son sensibles a la magnitud de los datos y pueden verse dominados por variables numéricas con valores mayores. En este proyecto, se aplicó escalado a variables como la edad, el monto de facturación y la duración de estancia hospitalaria, utilizando técnicas como la normalización o estandarización [4]. Así, el proceso ayuda a que el modelo aprenda patrones de forma más eficiente y evite sesgos numéricos.

5. Codificación de datos categóricos

Los modelos de machine learning requieren que todas las variables de entrada sean numéricas. Por ello, las variables categóricas (como género, tipo de sangre, condición médica, tipo de admisión, resultados de pruebas) necesitan ser codificadas [5]. Se emplean técnicas como la codificación one-hot (que convierte cada categoría en una columna binaria) o la codificación ordinal si la variable tiene un orden implícito [6]. Este paso transforma atributos como *"Gender"*, *"Medical Condition"*, *"Admission Type"*, etc., en una representación numérica apta para el entrenamiento del modelo, logrando que la información categórica se utilice en la predicción.

6. Pipeline final de Procesamiento

Para asegurar la reproducibilidad y organización del proyecto, se estructuró un pipeline de procesamiento de datos. Un pipeline es una secuencia de pasos automatizados que aplican consecutivamente las transformaciones necesarias al conjunto de datos desde la entrada hasta la obtención del dataset listo para el modelado [7]. Este pipeline incluye la selección de variables relevantes, la imputación de valores faltantes si existieran, la generación de nuevos atributos, el escalado de variables numéricas y la codificación de variables categóricas. De este modo, se facilita la integración del procesamiento al flujo de trabajo y permite aplicar los mismos pasos tanto a los datos de entrenamiento como a los de prueba en futuras implementaciones.

IX. ANÁLISIS DE RESULTADOS

Para evaluar el desempeño del modelo predictivo

desarrollado, se analizaron tanto métricas cuantitativas como representaciones visuales derivadas del comportamiento del dataset y del proceso de entrenamiento. La **Figura 1** muestra la distribución de la variable objetivo Length of Stay, donde se observa una alta variabilidad entre pacientes, lo que confirma que la predicción de la estancia hospitalaria es un reto estadístico debido a su naturaleza dispersa.




Figura 1. Distribución de la duración de hospitalización (Length of Stay).

En la etapa de preparación de datos, la estratificación del dataset por grupos de edad contribuyó a preservar la representación poblacional entre conjuntos de entrenamiento y prueba. Esto se refleja en la **Figura 2**, donde se evidencia que los porcentajes por categoría de edad permanecen consistentes en los tres subconjuntos, confirmando que el método reduce sesgos y mejora la generalización del modelo.




Figura 2. Comparación de proporciones por grupo de edad entre dataset completo y particiones estratificadas.

Posteriormente, se entrenaron tres modelos iniciales: regresión lineal, árbol de decisión y bosque aleatorio. Como se observa en la **Figura 3**, el bosque aleatorio presentó el menor RMSE en validación cruzada, lo que justificó su selección como punto de partida para la optimización. Este comportamiento sugiere que los métodos basados en árboles son más adecuados para capturar relaciones no lineales entre características clínicas y duración hospitalaria.




Figura 3. Desempeño comparativo de modelos según RMSE promedio.

Una vez optimizado mediante Grid Search, el modelo final fue evaluado sobre datos no vistos. La **Figura 4** representa los valores reales frente a las predicciones generadas, evidenciando una tendencia alineada a la diagonal ideal, aunque con dispersión atribuible a la baja correlación directa entre variables originales y la respuesta. Esto se refuerza con la **Figura 5**, que muestra la distribución del error del modelo, donde la mayoría de las predicciones oscilan dentro de ± 8 días, reflejando tanto utilidad práctica como margen de mejora.




Figura 4.

Relación entre valores reales y predicciones del modelo final.




Figura 5.

Distribución de errores del modelo sobre el conjunto de prueba.

Finalmente, la **Figura 6** presenta la importancia relativa de las características dentro del modelo. Se destaca que transformaciones numéricas como $\log$ (*Billing Amount*), *Room*

Number y la relación monto/edad influyen más en la predicción que variables descriptivas como condición médica o tipo de admisión. Este resultado coincide con el análisis previo de correlaciones débiles y justifica el uso de modelos complejos capaces de detectar interacciones entre atributos.




Figura 6. Importancia relativa de atributos en el modelo Random Forest.

Finalmente, los resultados obtenidos permiten afirmar que los modelos basados en árboles, particularmente el bosque aleatorio optimizado, se adaptan adecuadamente a patrones no lineales presentes en los datos. No obstante, el margen de error alcanzado evidencia la necesidad de integrar información clínica más detallada, así como técnicas adicionales de ingeniería de atributos, para mejorar la capacidad predictiva del sistema.

X. RECOMENDACIONES

Se recomienda enriquecer el dataset con información médica más específica, como signos clínicos, historial de tratamiento, severidad diagnóstica y comorbilidades, ya que esto podría reducir significativamente el error predictivo. También sería útil explorar algoritmos más avanzados para obtener mayor desempeño cuando existen interacciones complejas entre variables.

De manera operativa, se sugiere generar atributos adicionales relacionados con variación temporal, carga hospitalaria o urgencia clínica. Finalmente, replicar este estudio con datos reales y aplicar técnicas explicativas que permitan validar la utilidad del modelo en un entorno asistencial real, mejorar su interpretación y apoyar decisiones de planificación hospitalaria.

XI. CONCLUSIONES

El modelo construido logró predecir la duración de hospitalización con una precisión moderada y una variabilidad estable entre validaciones, demostrando que los enfoques no lineales como Random Forest son adecuados para capturar patrones complejos en datos clínicos básicos. Su rendimiento superó a modelos lineales y árboles simples, lo que valida las decisiones metodológicas implementadas, incluyendo transformación de atributos, estratificación y refinamiento con Grid Search.

No obstante, el margen de error obtenido evidencia que la información disponible es limitada para estimaciones más precisas. Esto se debe a la baja correlación entre variables originales y duración de estancia, así como al carácter sintético del dataset. Aun así, los resultados confirman que el proyecto constituye un punto de partida viable y generalizable para aplicaciones en contexto hospitalario, siempre y cuando se complementen con datos clínicos reales y atributos más representativos.

XII. REFERENCIAS

- [1] H. Zhang, L. Chen, and P. Kumar, “Length of Stay Prediction in Hospitals Using Machine Learning Models,” *BMC Medical Informatics and Decision Making*, vol. 20, no. 328, pp. 1–12, 2020.
- [2] A. García and M. Fernández, “Feature Engineering Techniques for Health Data Analysis,” *Journal of Big Data*, vol. 8, no. 112, pp. 1–15, 2021.
- [3] Scikit-learn Developers, “Preprocessing Data: Scaling, Centering, Normalization,” *scikit-learn.org*, 2023. [En línea]. Disponible en: <https://scikit-learn.org/stable/modules/preprocessing.html>. [Accedido: 10-nov-2025].
- [4] A. Géron, *Hands-On Machine Learning with Scikit-Learn, Keras and TensorFlow*, 3rd ed. Sebastopol, CA: O’Reilly Media, 2022.
- [5] M. C. Fernandes et al., “Categorical Data Encoding Techniques for Machine Learning: A Comparative Study,” *IEEE Access*, vol. 9, pp. 124520–124534, 2021.
- [6] Scikit-learn Developers, “Encoding Categorical Features,” *scikit-learn.org*, 2024. [En línea]. Disponible en: <https://scikit-learn.org/stable/modules/preprocessing.html#encoding-categorical-features>. [Accedido: 10-nov-2025].
- [7] P. S. Dutta and J. Singh, “Machine Learning Pipelines: Concepts and Best Practices,” *IEEE Access*, vol. 9, pp. 153994–154006, 2021.

