



SC-707 BIG DATA

# PREDICTOR DE TIEMPO DE HOSPITALIZACIÓN

Daniela Carreño Cordón,  
Daniel Centeno Rivera,  
Brayton Maccoy Artola y  
Kathleen Venegas Bermúdez





# HEALTHCARE DATASET

Dataset sintético de atención médica con **55 500 registros** y **15 columnas**, que incluye información demográfica, médica y administrativa de pacientes.

## **Campos principales:**

- Age, Gender, Blood Type
- Medical Condition, Admission Type, Insurance Provider
- Medication, Test Results
- Billing Amount, Room Number
- Date of Admission, Discharge Date

## **Variable objetivo:**

Length of Stay (días de hospitalización)

## **Obtenida como:**

Discharge Date – Date of Admission



# PREPROCESAMIENTO

## Numéricas:


- Age y Billing Amount: imputación por mediana, transformación logarítmica y estandarización
- Billing\_per\_age: nueva variable ( $\text{Billing Amount} / \text{Age}$ )
- Room Number: imputación por mediana y estandarización

## Categorías:

- Gender, Blood Type, Medical Condition, Admission Type, Insurance Provider, Medication, Test Results  
→ imputación por moda + One-Hot Encoding

## Otras decisiones:

- Eliminación de Name, Doctor, Hospital
- Conversión de fechas a Length of Stay
- Inserción intencional de valores nulos para evaluar el preprocesamiento
- Separación Train/Test estratificada por edad
- Implementado mediante: ColumnTransformer + Pipeline





# ENTRENAMIENTO Y SELECCIÓN DE MODELOS

Se entrenaron tres modelos usando el mismo pipeline de preprocesamiento y validación cruzada:

## **Modelo A — Regresión Lineal**

- RMSE promedio  $\approx 10.4$  días
- Limitado por relaciones no lineales

## **Modelo B — Árbol de Decisión**

- RMSE  $\approx 11$ – $12$  días
- Tendencia al sobreajuste

## **Modelo C — Random Forest (mejor desempeño)**

- RMSE promedio  $\approx 8.6$ – $8.8$  días
- Mejor estabilidad y menor error en las pruebas







# MODELO SELECCIONADO

**Optimizado mediante Grid Search**, explorando combinaciones de:

- `n_estimators`: 100, 200
- `max_depth`: 8, 12, 16
- `max_features`: "sqrt", "log2"
- `min_samples_split`: 2, 5
- `min_samples_leaf`: 1, 2

**Mejores hiperparámetros encontrados:**

- `n_estimators`: 200
- `max_depth`: 16
- `max_features`: log2
- `min_samples_split`: 2
- `min_samples_leaf`: 1

**Rendimiento:**

- RMSE (cross-validation):  $\approx 8.58$  días
- RMSE en el conjunto de prueba:  $\approx 8.6$  días
- Intervalo de confianza del 95% calculado sobre el conjunto test





# ANÁLISIS DE RESULTADOS Y SUGERENCIAS

## Conclusiones del modelo

- El Random Forest predice la estancia hospitalaria con un error estable de  $\approx$  **8.6** días.
- Mostró mejor generalización comparado con Regresión Lineal y Árbol de Decisión.
- Las variables más influyentes fueron: Billing Amount (y su versión log), Age, Admission Type, Medical Condition, Medication y Test Results.

## Sugerencias para una siguiente iteración:

- Incorporar más información clínica detallada para mejorar precisión.
- Probar modelos avanzados como Gradient Boosting, XGBoost o LightGBM.
- Refinar variables categóricas y crear nuevas características clínicas.
- Evaluar el modelo en datos reales del entorno hospitalario.

